

UNIVERSITÉ DE POITIERS
IUT — Département Science des Données

Analyse bibliométrique d'un laboratoire de recherche à partir de données ouvertes

*Cas d'étude : Laboratoire LIAS
(Informatique & Automatique pour les Systèmes)*

BUT 2 — Science des Données

Année universitaire 2025–2026

SAE - Développement d'un composant d'une solution décisionnelle

Table des matières

1	Contexte et enjeux	3
2	Objectif pédagogique	3
3	Sources de données	4
3.1	DBLP (dblp.org) — Publications	4
3.2	Theses.fr — Thèses de doctorat	5
3.3	CORE Rankings (portal.core.edu.au) — Qualité des conférences	5
3.4	SCImago Journal Rank (scimagojr.com) — Qualité des journaux	5
3.5	Autres sources (hors périmètre — perspective A&S)	6
3.6	Limites connues et biais	6
4	Indicateurs à calculer	7
4.1	Indicateurs de volume	7
4.2	Indicateurs de qualité et d'impact	7
4.3	Indicateurs de collaboration	8
4.4	Indicateurs doctoraux	8
4.5	Indicateurs d'importance individuelle et de risque	8
5	Architecture applicative : FastAPI + Streamlit	10
5.1	Backend — API REST avec FastAPI	10
5.2	Frontend — Dashboard Streamlit	10
5.3	Module de simulation (essentiel)	11
5.4	Déploiement avec Docker Compose	12
6	Questions d'analyse stratégique	14
6.1	La fusion IDD + SETR est-elle équilibrée ?	15
6.2	Qualité des publications : qui publie dans les meilleures venues ?	15
6.3	Importance des membres, risque de dépendance et non-implication	15
6.4	Dynamiques et tendances	16
6.5	Projection à 5 ans : quel avenir pour l'équipe fusionnée ?	16
6.6	Question ouverte (bonus)	17
7	Livrables attendus	17
8	Critères d'évaluation	18
9	Ressources techniques	18
9.1	API DBLP — Exemples de requêtes	18
9.2	API HAL — Exemples de requêtes (perspective A&S)	18
9.3	CORE Rankings — Accès	19
9.4	SCImago — Accès	19
9.5	Technologies suggérées	19

9.6 Liste des membres IDD et SETR	19
10 Composition des groupes	20
11 Consignes importantes	20
12 Perspectives : extension à l'équipe A&S	20

1 Contexte et enjeux

Le laboratoire LIAS (**L**aboratoire d'**I**nformatique et d'**A**utomatique pour les **S**ystèmes) est une unité de recherche rattachée à l'Université de Poitiers et à l'ISAE-ENSMA. Il regroupe **41 chercheurs permanents** répartis en trois équipes :

Équipe	Effectif	Thématiques
IDD (Data Engineering)	11	Bases de données, Web sémantique, IA explicable, Big Data
SETR (Systèmes Temps Réel)	8	Ordonnancement temps réel, réseaux embarqués, avionique
A&S (Automatique & Systèmes)	22	Commande, identification, systèmes fractionnaires, diagnostic

TABLE 1 – Répartition des chercheurs permanents du LIAS. Les équipes en surbrillance constituent le périmètre de ce projet.

Périmètre du projet :

- **Équipes** : IDD (11 membres) et SETR (8 membres), soit **19 chercheurs**
- **Période d'analyse** : janvier 2021 – décembre 2025 (5 années complètes)
- **Source principale** : DBLP (bien adapté aux thématiques informatique de ces deux équipes)

L'équipe A&S (22 membres) est exclue du périmètre car ses publications relèvent de domaines peu couverts par DBLP et nécessiteraient des sources différentes (HAL, Scopus, IEEE Xplore). L'extension à A&S constitue une **perspective ouverte** (voir section 12).

Important : toute publication, thèse ou indicateur calculé dans ce projet doit concerner **exclusivement la période janvier 2021 – décembre 2025**. Les publications antérieures ou postérieures doivent être exclues.

Enjeu stratégique principal : La direction du laboratoire envisage la **fusion des équipes IDD et SETR**. Ce projet vous place dans un rôle de *data analyst* au service de la décision stratégique.

Enjeu complémentaire : Au-delà de la fusion, la direction souhaite disposer d'un **outil d'aide à la décision** permettant de simuler l'impact de la **marginalisation** ou du transfert d'un chercheur sur les performances de son équipe et du laboratoire. Certains membres ont un poids disproportionné dans la production scientifique : leur mise à l'écart dans une nouvelle organisation pourrait fragiliser une équipe entière. L'outil doit rendre visible cette dépendance.

2 Objectif pédagogique

Ce projet mobilise l'ensemble de la chaîne de valeur d'un projet data, de la collecte brute à la mise en production d'une application web :

- **Collecte** de données via des API ouvertes (DBLP, theses.fr) et des référentiels qualité (CORE, Scimago)
- **Nettoyage et fiabilisation** (désambiguation, filtrage)
- **Enrichissement qualitatif** : classement CORE des conférences, quartile Scimago des journaux
- **Modélisation et calcul** d'indicateurs de volume, qualité et impact
- **Développement d'une API REST** avec FastAPI pour exposer les données et les indicateurs
- **Construction d'un dashboard interactif** avec Streamlit, incluant la simulation de scénarios (marginalisation, transferts)
- **Analyse critique** et recommandations stratégiques

Approche impérative : données d'abord. La fiabilité des données est la fondation du projet. Aucun indicateur, aucune visualisation, aucune application ne peut être construite sur des données non validées. La première phase (collecte + fiabilisation + validation par chercheur) doit être terminée et vérifiée avant de passer au développement de l'application.

3 Sources de données

3.1 DBLP (dblp.org) — Publications

DBLP est la principale base bibliographique en informatique. Elle recense articles de journaux, communications en conférences, éditoriaux, etc. C'est la **source principale** de ce projet pour les équipes IDD et SETR, dont les thématiques sont bien couvertes par DBLP.

API disponibles (format XML)

- Recherche d'auteur : `/search/author/api?q={nom}&format=xml`
- Publications par PID : `/pid/{id}.xml` (méthode la plus fiable pour éviter les homonymes)
- Recherche de publications : `/search/publ/api?q=author:{nom}:+year:{année}&format=xml`

Note : l'API DBLP retourne les données au format **XML**. Le format JSON n'est pas disponible pour tous les endpoints. Utilisez un parseur XML (par exemple `xml.etree.ElementTree` en Python ou le package `xml2` en R) pour exploiter les réponses.

Filtrage requis

Attention : ne garder que les contributions scientifiques *peer-reviewed*. Exclure : éditoriaux (*proceedings editor*), livres, CoRR/arXiv (prépublications non relues).

Problème des homonymes

Certains noms sont très courants sur DBLP (ex : Patrick Girard renvoie 6 chercheurs différents). La désambiguation par PID est indispensable. DBLP attribue des suffixes (0001, 0002...) avec des affiliations.

3.2 Theses.fr — Thèses de doctorat

Base nationale des thèses de doctorat françaises. Permet d'identifier les thèses dirigées ou co-dirigées par chaque chercheur (soutenues et en cours).

3.3 CORE Rankings (portal.core.edu.au) — Qualité des conférences

CORE (*Computing Research and Education Association of Australasia*) fournit un classement international des conférences en informatique, régulièrement mis à jour. Chaque conférence est classée selon le barème suivant :

Rang	Libellé	Description
A*	Flagship	Conférence phare du domaine, très sélective (top ~5% des soumissions)
A	Excellent	Conférence de très haut niveau, large reconnaissance internationale
B	Good	Bonne conférence avec une visibilité significative dans le domaine
C	Other	Conférence reconnue, portée plus limitée
Non classée	—	Conférence absente du référentiel CORE

TABLE 2 – Barème de classement CORE

Accès aux données CORE

- Recherche en ligne : <https://portal.core.edu.au/conf-ranks/>
- Le portail ne propose **pas d'export CSV**. Les rangs doivent être récupérés manuellement ou par scraping de la page de résultats
- **Stratégie recommandée** : extraire les acronymes des conférences depuis DBLP (balise <booktitle>), puis rechercher chaque acronyme sur le portail CORE et construire manuellement (ou par script) une table de correspondance **acronyme** → **rang**

3.4 SCImago Journal Rank (scimagojr.com) — Qualité des journaux

SCImago fournit un classement des revues scientifiques basé sur les données Scopus. Chaque journal est classé en quartiles (Q1 à Q4) par domaine :

Quartile	Signification	Description
Q1	Top 25%	Les meilleures revues du domaine (forte sélectivité, haut facteur d'impact)
Q2	25–50%	Revue de bon niveau, reconnues internationalement
Q3	50–75%	Revue de niveau intermédiaire
Q4	75–100%	Quartile inférieur, visibilité plus faible
Non classé	—	Journal absent de Scopus / SCImago

TABLE 3 – Quartiles SCImago

Accès aux données Scimago

- Recherche en ligne : <https://www.scimagojr.com/journalrank.php>
- Téléchargement CSV complet : <https://www.scimagojr.com/journalrank.php?out=xls>
- **Stratégie recommandée** : extraire le nom du journal depuis DBLP (balise <journal>), puis croiser avec le fichier Scimago par titre ou ISSN
- **Indicateur SJR** : en plus du quartile, le score SJR est un indicateur continu permettant des comparaisons plus fines entre journaux d'un même quartile

3.5 Autres sources (hors périmètre — perspective A&S)

Source	Intérêt	Accès
HAL	Archive ouverte nationale. Indispensable pour A&S (automatique).	https://api.archives-ouvertes.fr
Scopus	Base Elsevier, très complète pour l'automatique. Citations, H-index.	API avec clé institutionnelle
IEEE Xplore	Incontournable pour A&S : IEEE TAC, CDC, ACC.	https://developer.ieee.org
OpenAlex	Base ouverte agrégeant Crossref, PubMed, etc.	https://api.openalex.org

TABLE 4 – Sources complémentaires (utiles pour l'extension à A&S)

Ces sources ne sont pas nécessaires pour le périmètre actuel (IDD + SETR) mais seraient indispensables pour une extension à l'équipe A&S (voir section 12).

3.6 Limites connues et biais

- DBLP est centré informatique : bien adapté pour IDD et SETR, mais insuffisant pour A&S (hors périmètre)
- Certains chercheurs n'ont aucune entrée DBLP — documenter ces cas
- Le *rate-limiting* de l'API DBLP impose des délais ($\sim 2-3$ secondes). Stocker les réponses localement pour ne pas re-télécharger
- SCImago peut classer un même journal dans des quartiles différents selon la catégorie choisie — choisir la catégorie la plus pertinente
- Les données DBLP sont au format XML uniquement pour les endpoints PID

4 Indicateurs à calculer

4.1 Indicateurs de volume

Indicateur	Définition	Granularité
Nombre total de publications	Journaux + Conférences (hors éditoriaux, CoRR)	Équipe, membre, an
Productivité par membre	Total publications / nombre de permanents	Par équipe
Productivité par membre actif	Total / membres ayant au moins 1 publication	Par équipe
Taux de membres actifs	% de membres avec ≥ 1 publication	Par équipe
Ratio journaux / conférences	Proportion d'articles de journaux	Équipe, membre
Évolution annuelle	Tendance 2021 $\rightarrow$ 2025	Par équipe

TABLE 5 – Indicateurs de volume

4.2 Indicateurs de qualité et d'impact

Indicateur	Définition	Source
Rang CORE	Distribution des publications par rang CORE (A*, A, B, C, non classé)	CORE
Quartile Scimago	Distribution par quartile (Q1–Q4, non classé). % de Q1	SCImago
Score qualité pondéré	A*=4, A=3, B=2, C=1, NC=0 (conf.) ; Q1=4, Q2=3, Q3=2, Q4=1 (journaux)	CORE + SCImago
Top venues	Publications dans les conférences A*/A ou revues Q1/Q2	CORE + SCImago
Diversité des venues	Nombre de venues différentes (indice de Shannon)	DBLP
SJR moyen	Moyenne du SCImago Journal Rank des revues	SCImago

TABLE 6 – Indicateurs de qualité et d'impact

4.3 Indicateurs de collaboration

Indicateur	Définition	Difficulté
Collaborations intra-équipe	Nombre de co-publications entre membres de la même équipe	★★
Collaborations inter-équipes	Co-publications entre membres d'équipes différentes	★★
Taux d'ouverture	% de publications avec au moins un co-auteur externe au LIAS	★★
Graphe de collaboration	Réseau de co-publications (nœuds = chercheurs, arêtes = co-publications)	★★★

TABLE 7 – Indicateurs de collaboration

4.4 Indicateurs doctoraux

Indicateur	Définition	Source
Thèses soutenues	Nombre de thèses soutenues par équipe (2021–2025)	theses.fr
Thèses en cours	Nombre de thèses en cours par équipe	theses.fr
Taux d'encadrement	Nombre de HDR / PR encadrant au moins 1 thèse	Croisement
Co-publications doctorant/directeur	Publications issues de travaux de thèse	DBLP + theses.fr

TABLE 8 – Indicateurs doctoraux

4.5 Indicateurs d'importance individuelle et de risque

Ces indicateurs visent à identifier à la fois les chercheurs clés (« locomotives ») dont la marginalisation fragiliserait l'équipe, et les **membres peu ou non impliqués** dans la recherche, dont la présence peut masquer la productivité réelle de l'équipe.

Indicateur	Définition	Usage
<i>Impact positif — chercheurs clés</i>		
Part de production (%)	Publications du membre / Total équipe. >30% = risque de concentration	Dépendance
Score qualité individuel	Score CORE/Scimago pondéré vs. moyenne de l'équipe	Impact qualitatif
Indice de centralité	<i>Betweenness centrality</i> dans le graphe de co-publication	Rôle structurant
Impact simulé de la marginalisation	Recalcul des indicateurs en réduisant la production du membre (ex. −50% ou −100%). Écart en %	Simulation
Impact simulé du transfert	Déplacement d'un membre : recalcul des indicateurs des deux équipes	Simulation
<i>Impact négatif — membres peu impliqués</i>		
Statut d'activité	Classement en 3 niveaux : actif (≥ 3 publications sur la période), peu actif (1–2 publications), inactif (0 publication)	Diagnostic
Impact sur la productivité	Écart entre productivité par membre (incluant les inactifs) et productivité par membre actif. Plus l'écart est grand, plus les inactifs « diluent » la performance	Alerte
Effet de lest	Simulation inverse : recalcul des indicateurs d'équipe <i>en excluant les membres inactifs</i> . Mesure le gain de productivité et de score qualité si l'équipe ne comptait que ses membres actifs	Simulation
<i>Distribution</i>		
Indice de Gini	Mesure l'inégalité de production au sein de l'équipe. Proche de 1 = production très concentrée sur quelques membres	Équilibre

TABLE 9 – Indicateurs d'importance individuelle et de risque

5 Architecture applicative : FastAPI + Streamlit

L'application est le **livrable central** du projet. Elle repose sur une architecture en deux couches orchestrée par **Docker Compose** : une **API REST** (FastAPI) qui expose les données et les indicateurs, et un **frontend interactif** (Streamlit) qui consomme cette API pour offrir le dashboard et les simulations. L'ensemble doit être déployable en une seule commande (`docker compose up`).

5.1 Backend — API REST avec FastAPI

FastAPI est un framework Python moderne, performant et bien documenté pour construire des API REST. L'API constitue le socle de l'application : elle centralise l'accès aux données et la logique métier.

Endpoints attendus

Endpoint	Description	Paramètres
GET /api/membres	Liste des membres avec équipe, statut, nombre de publications	?equipe=IDD
GET /api/membres/{id}	Fiche détaillée d'un membre	—
GET /api/publications	Publications avec filtres multi-critères	?equipe=...
GET /api/equipes/{id}/indicateurs	Indicateurs d'une équipe	?annee_debut=...
POST /api/simulation/marginalisation	Simule la marginalisation d'un ou plusieurs membres (réduction de production)	Body JSON
POST /api/simulation/transfert	Simule le transfert d'un membre	Body JSON
GET /api/collaboration/graphe	Graphe de co-publications au format JSON	?equipe=IDD

TABLE 10 – Endpoints de l'API REST

Exigences techniques FastAPI

- **Documentation automatique** : FastAPI génère une documentation Swagger (/docs) et ReDoc (/redoc). Cette documentation est un livrable
- **Modèles Pydantic** : schémas pour `Membre`, `Publication`, `Equipe`, `Indicateurs`, `SimulationResult`
- **Source de données** : les fichiers Excel validés servent de source primaire. L'API les charge au démarrage
- **Séparation des responsabilités** : la logique de calcul est dans l'API, pas dans Streamlit

5.2 Frontend — Dashboard Streamlit

Streamlit permet de construire rapidement des interfaces interactives en Python. Il consomme l'API FastAPI via des requêtes HTTP.

Pages attendues

- **Vue d'ensemble** : KPI globaux du laboratoire, évolution temporelle, répartition par équipe
- **Comparaison des équipes** : graphiques superposés IDD vs. SETR
- **Fiche chercheur** : sélection d'un membre, publications, part dans l'équipe, co-auteurs, qualité des venues
- **Graphe de collaboration** : visualisation interactive du réseau de co-publications
- **Module de simulation** : page dédiée à la simulation de marginalisations et transferts

5.3 Module de simulation (essentiel)

Le module de simulation est un **livrable obligatoire**. Il utilise les endpoints POST de l'API pour recalculer les indicateurs en temps réel.

Scénario 1 : Marginalisation d'un membre

- L'utilisateur sélectionne un ou plusieurs membres et un **taux de réduction** de leur production (ex. -50% , -75% , -100%)
- L'API recalcule : publications, productivité, score qualité moyen, taux membres actifs, indice de Gini
- Streamlit affiche l'écart en % (`st.metric` avec delta rouge/vert)
- Mise en évidence si la marginalisation fait passer un indicateur sous un seuil critique
- Cas d'usage : simuler ce qui se passe si un chercheur clé est mis à l'écart dans la nouvelle organisation (perte de collaborations, exclusion de projets, etc.)

Scénario 2 : Transfert d'un membre vers une autre équipe

- L'utilisateur déplace un membre vers une équipe d'accueil
- L'API recalcule les indicateurs des deux équipes simultanément
- Streamlit affiche côte à côte (`st.columns`) : équipe d'origine (avant/après) et équipe d'accueil (avant/après)
- Cas d'usage principal : simuler la fusion IDD+SETR en transférant progressivement les membres

Exemples de questions que le module doit permettre de répondre

- Si Ladjel Bellatreche est marginalisé dans IDD (-50% de production), quel est l'impact sur la productivité et le score qualité de l'équipe ?
- Si on transfère un membre de SETR vers IDD, l'équipe fusionnée est-elle plus équilibrée ?
- Quels sont les 3 chercheurs dont la marginalisation aurait le plus fort impact négatif ?

5.4 Déploiement avec Docker Compose

L'ensemble de l'application doit être conteneurisé avec **Docker** et orchestré via **Docker Compose**. L'objectif est de permettre à n'importe qui de lancer le projet complet en une seule commande, sans installation préalable (hormis Docker lui-même).

Architecture des conteneurs

Service	Port	Rôle
api	8000	Backend FastAPI (uvicorn). Expose /docs et les endpoints REST
dashboard	8501	Frontend Streamlit. Consomme l'API via le réseau Docker interne

TABLE 11 – Services Docker Compose

Volumes pour les données locales

Les fichiers de données (Excel validés, CSV de référentiels, fichiers de configuration) sont montés comme **volumes Docker** depuis le répertoire local du projet. Cela permet de :

- **Modifier les données sans reconstruire les images** : les fichiers Excel des chercheurs, les tables CORE et Scimago peuvent être mis à jour directement sur la machine hôte
- **Saisir des informations manuellement** : un fichier de configuration local (par ex. `data/membres.csv` ou `data/overrides.csv`) permet de renseigner manuellement des informations non disponibles via les API (PID DBLP corrigés, affiliations, corrections de noms, etc.)
- **Persister les résultats** : les fichiers générés (Excel enrichis, caches des requêtes API) sont stockés dans le volume partagé

Structure attendue

```

projet/
  docker-compose.yml
  api/
    Dockerfile
    requirements.txt
    main.py, routers/, models/, services/
  dashboard/
    Dockerfile
    requirements.txt
    app.py, pages/
  data/
    # Volume monté dans les deux conteneurs
    membres.csv      # Liste des membres (saisie manuelle)
    overrides.csv     # Corrections manuelles (PID, noms...)
    scimago.csv       # Référentiel Scimago (téléchargé)
    core_ranks.csv    # Référentiel CORE (saisi manuellement ou par scraping)

```

```

chercheurs/      # Un .xlsx par chercheur (généralisé)
cache/           # Cache des réponses API DBLP

```

Exigences Docker

- **Un Dockerfile** par service (API et Dashboard), basé sur une image Python légère (python:3.11-slim ou équivalent)
- **Un docker-compose.yml** définissant les deux services, le réseau interne et les volumes
- **Lancement en une commande** : `docker compose up --build` doit suffire pour démarrer l'ensemble
- **Variables d'environnement** : l'URL de l'API (utilisée par Streamlit) doit être configurable via le fichier `docker-compose.yml` (ex. `API_URL=http://api:8000`)
- **Le répertoire data/** est monté en lecture-écriture dans les deux conteneurs, permettant à l'API de lire les données et d'écrire les résultats

Structure complète du projet

Un squelette de départ vous est fourni avec les Dockerfiles, le `docker-compose.yml` et les fichiers `requirements.txt` pré-remplis. Vous devez compléter le code applicatif.

```

projet/
  docker-compose.yml      # Orchestration (fourni)
  .env                    # Variables d'environnement
  .gitignore
  README.md               # Instructions de lancement

api/                      # Service FastAPI
  Dockerfile              # (fourni)
  requirements.txt         # (fourni)
  main.py                 # Point d'entrée FastAPI
  models/                 # Modèles Pydantic
    membre.py
    publication.py
    equipe.py
    simulation.py
  routers/                # Endpoints REST
    membres.py
    publications.py
    equipes.py
    simulation.py
    collaboration.py
  services/               # Logique métier
    data_loader.py        # Chargement des données

```

indicators.py	# Calcul des indicateurs
collaboration.py	# Graphe de co-publications
simulation.py	# Moteur de simulation
dashboard/	# Service Streamlit
Dockerfile	# (fourni)
requirements.txt	# (fourni)
app.py	# Point d'entrée (navigation)
api_client.py	# Client HTTP vers FastAPI
pages/	
1_vue_ensemble.py	
2_comparaison.py	
3_fiche_chercheur.py	
4_collaboration.py	
5_simulation.py	
scripts/	# Pipeline de collecte (hors Docker)
01_collect_dblp.py	
02_parse_dblp.py	
03_collect_theses.py	
04_enrich_core.py	
05_enrich_scimago.py	
06_generate_excel.py	
utils.py	
notebooks/	# Exploration et analyse
exploration.ipynb	
data/	# Volume monté (données éditables)
membres.csv	# Liste des 19 membres (saisie manuelle)
overrides.csv	# Corrections manuelles
scimago.csv	# Référentiel Scimago
core_ranks.csv	# Référentiel CORE (saisi/scrapé)
cache/	
dblp/	# Cache XML par chercheur
output/	
chercheurs/	# Un .xlsx par chercheur
consolidated.xlsx	# Fichier consolidé

6 Questions d'analyse stratégique

Ces questions constituent le cœur de votre analyse. Elles doivent être traitées avec des données, des visualisations et des arguments étayés. Il n'y a pas de « bonne réponse » : c'est la

qualité de l'argumentation qui sera évaluée.

6.1 La fusion IDD + SETR est-elle équilibrée ?

- Quel est l'écart de productivité (par membre) entre IDD et SETR ? Cet écart est-il significatif ou s'explique-t-il par des différences structurelles (taille, séniorité) ?
- Existe-t-il déjà des collaborations entre IDD et SETR (co-publications) ? Quels sont les chercheurs « ponts » ?
- La fusion créerait une équipe de 19 membres. Quelle serait sa productivité globale ? L'équipe fusionnée serait-elle équilibrée en termes de thématiques ?
- Y a-t-il un risque que SETR soit « absorbée » plutôt que réellement fusionnée ? Quels indicateurs permettraient de le détecter *a posteriori* ?

6.2 Qualité des publications : qui publie dans les meilleures venues ?

- Quelle est la distribution des rangs CORE (A*, A, B, C) pour chaque équipe ? IDD publie-t-elle dans de meilleures conférences que SETR ?
- Quelle est la distribution des quartiles Scimago (Q1, Q2, Q3, Q4) des articles de journaux par équipe ? Qui publie le plus en Q1 ?
- Le score qualité pondéré (CORE + Scimago) change-t-il les conclusions basées uniquement sur le volume ?

6.3 Importance des membres, risque de dépendance et non-implication

- Identifiez les chercheurs « locomotives » de chaque équipe (part de production > 25%). Quel risque représente leur marginalisation ?
- Utilisez le module de simulation pour calculer l'impact de la marginalisation du chercheur le plus productif de chaque équipe (−50%, puis −100%). Quelle équipe est la plus vulnérable ?
- L'indice de Gini révèle-t-il des équipes où la production est très inégalement répartie ?
- Si on simule le transfert d'un « pont » d'IDD vers SETR (ou inversement), les indicateurs de collaboration s'améliorent-ils ?
- **Membres peu ou non impliqués** : identifiez les membres inactifs (0 publication sur 2021–2025) et peu actifs (1–2 publications). Quel est leur poids dans chaque équipe ? Comment leur présence affecte-t-elle la productivité apparente ?
- **Effet de lest** : utilisez la simulation pour recalculer les indicateurs d'équipe *en excluant les membres inactifs*. La productivité par membre et le score qualité moyen s'améliorent-ils significativement ? Quelle équipe est la plus pénalisée par ses membres non impliqués ?
- Dans la perspective d'une fusion IDD+SETR, le cumul des membres inactifs des deux équipes constitue-t-il un risque de dilution de la performance de l'équipe fusionnée ?

6.4 Dynamiques et tendances

- Quelles équipes sont en croissance, stables ou en déclin sur 2021–2025 ?
- Le taux d’encadrement doctoral est-il corrélé à la production scientifique ? Un modèle linéaire simple le confirme-t-il ?
- La qualité des publications s’améliore-t-elle ou se dégrade-t-elle au fil des années ?

6.5 Projection à 5 ans : quel avenir pour l’équipe fusionnée ?

À partir des tendances observées sur 2021–2025, construisez un **modèle de projection** pour estimer la production scientifique de l’équipe fusionnée IDD+SETR sur la période **2026–2030**. L’objectif n’est pas de prédire avec exactitude, mais d’explorer des scénarios plausibles pour éclairer la décision de fusion.

Approche attendue

1. **Modélisation des tendances individuelles** : pour chaque membre, ajuster un modèle simple (régression linéaire, moyenne mobile) sur son historique de publications annuelles (2021–2025). Extrapoler la tendance sur 2026–2030.
2. **Scénarios de projection** : construire au minimum trois scénarios pour l’équipe fusionnée :
 - **Scénario tendanciel** (baseline) : chaque membre poursuit sa tendance actuelle, sans effet de la fusion
 - **Scénario optimiste** : la fusion génère des collaborations nouvelles entre IDD et SETR (hypothèse : +10–20% de co-publications inter-équipes), les membres peu actifs sont stimulés
 - **Scénario pessimiste** : les membres inactifs restent inactifs, un chercheur clé est marginalisé dans la nouvelle organisation (ses collaborations diminuent, sa production baisse de 50%), pas de synergie inter-équipes
3. **Indicateurs projetés** : pour chaque scénario, estimer sur 2026–2030 :
 - Le nombre total de publications par an
 - La productivité par membre
 - Le score qualité moyen (en supposant la répartition CORE/Scimago stable)
 - L’indice de Gini (évolution de l’inégalité)
4. **Visualisation** : graphiques montrant l’évolution 2021–2030 (données réelles puis projections) avec les intervalles entre scénarios optimiste et pessimiste

Limites à documenter

Toute projection repose sur des hypothèses fortes (tendances stables, effectifs constants, pas de recrutement ni de réorganisation imprévue). Ces limites doivent être explicitement documentées et discutées.

6.6 Question ouverte (bonus)

Proposez un scénario de simulation original (marginalisation, transfert, recrutement fictif) qui apporterait un éclairage supplémentaire sur la décision de fusion. Justifiez sa pertinence, exécutez-le dans le dashboard et interprétez les résultats.

7 Livrables attendus

N°	Description	Format
1	Dépôt Git — Code de collecte, nettoyage, analyse. Fichiers de données. README documentant le pipeline et les instructions de lancement Docker.	GitHub / GitLab
2	Données validées — Un fichier Excel par chercheur (onglets : Journaux avec quartile Scimago, Conférences avec rang CORE, Thèses, Rapports, Résumé) + fichier consolidé	.xlsx
3	Référentiels qualité — Table de correspondance conférence → rang CORE et journal → quartile/SJR Scimago	.xlsx / .csv
4	Environnement Docker — <code>docker-compose.yml</code> + Dockerfiles. Lancement en une commande : <code>docker compose up</code>	Docker
5	API REST (FastAPI) — API documentée (Swagger /docs) avec endpoints membres, publications, indicateurs, simulation. Modèles Pydantic.	Python / FastAPI
6	Dashboard (Streamlit) — Frontend interactif consommant l'API : filtres, simulation marginalisation/transfert, graphe de collaboration	Python / Streamlit
7	Note de synthèse — 2–3 pages répondant aux questions stratégiques avec scénarios de simulation documentés	.docx / .pdf
8	QCM individuel — Évaluation individuelle sur UPdago portant sur l'ensemble du projet (données, indicateurs, architecture, analyse). Date prévue : 05 mars 2026 .	UPdago

TABLE 12 – Livrables attendus

8 Critères d'évaluation

Critère	Poids	Détail
Qualité des données	20%	Fiabilité de la collecte, gestion des homonymes, complétude, enrichissement CORE/Scimago, documentation des limites
Analyse et indicateurs	20%	Pertinence des indicateurs (volume + qualité), rigueur des calculs, interprétation critique
Application (FastAPI + Streamlit + Docker)	25%	Architecture API bien conçue, documentation Swagger, module de simulation fonctionnel, qualité UX, déploiement Docker fonctionnel
Réponse aux questions stratégiques	25%	Profondeur de l'analyse, argumentation data-driven, scénarios de simulation pertinents, nuance, originalité
Qualité technique et collaboration	10%	Code propre, dépôt Git bien structuré, travail en équipe
QCM individuel (UPdago)	À définir	Évaluation individuelle portant sur la compréhension du projet, des données, des indicateurs et de l'architecture

TABLE 13 – Critères d'évaluation

9 Ressources techniques

9.1 API DBLP — Exemples de requêtes

Rechercher un auteur et obtenir son PID :

GET <https://dblp.org/search/author/api?q=Ladjel+Bellatreche&format=xml&h=5>

Récupérer toutes les publications d'un auteur via son PID (méthode recommandée) :

GET <https://dblp.org/pid/b/LadjelBellatreche.xml>

9.2 API HAL — Exemples de requêtes (perspective A&S)

L'API HAL serait nécessaire pour une extension à l'équipe A&S. À titre indicatif :

```
GET https://api.archives-ouvertes.fr/search/
    ?q=authFullName_s:"Olivier Bachelier"
    &fq=structId_i:117030
    &fq=producedDateY_i:[2021 TO 2025]
    &fl=title_s,producedDateY_i,docType_s,journalTitle_s,
        conferenceTitle_s
    &rows=200&wt=json
```

Paramètres utiles : `structId_i=117030` (LIAS), `docType_s` pour filtrer par type, `producedDateY_i` pour la période.

9.3 CORE Rankings — Accès

Recherche par acronyme de conférence :

```
https://portal.core.edu.au/conf-ranks/
    ?search=VLDB&by=all&source=CORE2023
```

Le portail ne propose pas d'export CSV. Les rangs doivent être récupérés manuellement ou par scraping.

9.4 SCImago — Accès

Téléchargement du classement complet (CSV/Excel) :

```
https://www.scimagojr.com/journalrank.php?out=xls
```

Ce fichier contient pour chaque journal : titre, ISSN, quartile (Best Quartile), SJR, H-index, catégorie, pays.

9.5 Technologies suggérées

- **Python** : `requests`, `pandas`, `openpyxl`, `matplotlib`, `plotly`, `networkx`
- **Backend API** : `FastAPI`, `uvicorn`, `pydantic`
- **Frontend Dashboard** : `Streamlit` (obligatoire), `requests` ou `httpx` pour consommer l'API
- **Graphe de collaboration** : `networkx` (Python) + `pyvis` ou `streamlit-agraph` pour la visualisation
- **Conteneurisation** : `Docker` + `Docker Compose` (obligatoire)
- **Versioning** : `Git` (obligatoire)

9.6 Liste des membres IDD et SETR

La liste complète des membres du LIAS est disponible sur <https://www.lias-lab.fr/members/>. Vous devrez identifier et extraire les **19 membres permanents** des équipes IDD (11) et SETR (8) comme première étape.

10 Composition des groupes

Vous pouvez travailler par groupes de **4 étudiants maximum**. Dès que votre groupe est formé, merci de communiquer sa composition via le lien suivant :

<https://lite.framacalc.org/723byzgqic-aic5>

11 Consignes importantes

- **Transparence sur les limites** : documenter systématiquement ce qui manque, ce qui est incertain, ce qui pourrait biaiser l'analyse
- **Approche progressive** : d'abord collecter et fiabiliser les données (jours 1–2), puis analyser (jours 3–5). Ne pas brûler les étapes
- **Respecter le rate-limiting** : attendre 2–3 secondes entre chaque requête DBLP. Stocker les réponses localement
- **Enrichir systématiquement** : chaque publication de conférence doit être associée à son rang CORE, chaque article de journal à son quartile Scimago. Documenter les cas non trouvés
- **Tout doit fonctionner via Docker** : un `docker compose up` doit suffire pour lancer l'API et le dashboard
- **Fichiers locaux éditables** : les données de référence (liste des membres, corrections manuelles, référentiels CORE/Scimago) sont dans le répertoire `data/` monté en volume. Il doit être possible de corriger une donnée manuellement sans modifier le code
- **Le dashboard doit être dynamique** : le module de simulation est un livrable obligatoire, pas un bonus
- **Utilisation des outils IA encouragée** : vous êtes vivement encouragés à utiliser des assistants IA (ChatGPT, Claude, Copilot, etc.) pour vous aider dans le développement : génération de code, débogage, rédaction de requêtes API, création des Dockerfiles, etc. L'IA est un outil professionnel que vous devez apprendre à maîtriser. **En revanche**, les interprétations des résultats, les recommandations stratégiques et l'analyse critique doivent rester les vôtres — l'IA ne peut pas remplacer votre compréhension des données et du contexte

12 Perspectives : extension à l'équipe A&S

L'équipe A&S (Automatique & Systèmes, 22 membres) a été volontairement exclue du périmètre de ce projet. Son intégration constitue une extension naturelle mais soulève des défis spécifiques liés à la nature différente de ses données bibliographiques.

Pourquoi A&S nécessite une approche différente

- **Couverture DBLP insuffisante** : DBLP est centré sur l'informatique et ne référence qu'une fraction des publications d'A&S. Les revues phares du domaine (IEEE Transactions

on Automatic Control, Automatica, Systems & Control Letters, etc.) et les conférences majeures (IFAC World Congress, CDC, ACC, ECC...) sont souvent absentes de DBLP.

- **Source principale : HAL.** L'archive ouverte nationale HAL (<https://hal.science>) est la source la plus complète pour couvrir l'équipe A&S. L'API HAL permet des requêtes par auteur et par structure (structId du LIAS = 117030).
- **Déduplication DBLP/HAL :** pour les membres d'A&S qui auraient des publications dans les deux bases, une déduplication serait nécessaire (comparaison par titre, année et auteurs).
- **Classement CORE limité :** le référentiel CORE ne couvre pas les conférences en automatique. Pour A&S, le quartile Scimago des journaux serait l'indicateur de qualité principal.
- **Sources complémentaires :** Scopus, IEEE Xplore et OpenAlex seraient des sources précieuses pour compléter la couverture d'A&S.

Pistes pour l'extension

L'architecture applicative (FastAPI + Streamlit) a été conçue pour être extensible. L'ajout d'A&S impliquerait principalement :

1. Développer un module de collecte HAL (en complément du module DBLP existant)
2. Implémenter la déduplication DBLP/HAL
3. Adapter les indicateurs de qualité (privilégier Scimago sur CORE pour A&S)
4. Étendre la comparaison inter-équipes à trois équipes (IDD vs. SETR vs. A&S)